

זיהוי כוס מלאה

בעזרת למידת מכונה והקלטות קוליות

מרצה: דימה בחובסקי

קורס: למידת מכונה

מגשים:

תומר נור מילקוב

ניקיטה בודובסקי

אורן גופמן

אור בלזר

תקציר

בפרויקט זה פותחה מערכת לזיהוי מילוי כוס באמצעות ניתוח אותות שמע ולמידת מכונה. המערכת מנתחת הקלטות של מזיגת מים, מחלצת מכל חלון זמן מאפיינים אקוסטיים, ומאמנת מסווג בינארי לזיהוי מצב שבו הכוס הגיעה לכ-90% מנפחה. מאגר הנתונים כולל 120 הקלטות מ-8 סוגי כוסות שונים. לאחר השוואה בין מספר מודלים, המודל שנבחר הוא LightGBM, שהציג את הביצועים הטובים ביותר בקוד החדש עם F1 של כ-0.735 ו-AUC-ROC של כ-0.968. התוצאות מצביעות על כך שאפשר לזהות את שלב המילוי הקרוב למלא בעזרת שמע בלבד, ללא שימוש בחיישנים נוספים.

1. מבוא

זיהוי גלישת מים במערכות מזיגה אוטומטיות הוא בעיה נפוצה בתחומים כמו רובוטיקה, מערכות בית חכם ומערכות בקרה. פתרונות קיימים לרוב מתבססים על חיישני משקל, חיישני מרחק אולטרסוניים או מצלמות. עם זאת, פתרונות אלו דורשים חומרה ייעודית, מיקום מדויק של החיישן ולעיתים גם התאמה פיזית לכלי הקיבול.

בעבודה זו נבדקת גישה חלופית: שימוש בניתוח אקוסטי פסיבי כדי להעריך את רמת המילוי של כוס מתוך הצליל בזמן מזיגת מים. כאשר הכוס מתמלאת, נפח האוויר שבתוכה קטן, ולכן מאפייני הצליל משתנים. שינוי זה הנוצר MFCC, spectral centroid, spectral rolloff, ספקטראליים שונים של האות, כגון בא לידי ביטוי במאפיינים מכל חלון זמן קצר בהקלטה ומאפיינים נוספים שחולצו.

המטרה המרכזית של הפרויקט היא לבנות מערכת למידת מכונה המסוגלת לזהות את השלב שבו הכוס מתקרבת למילוי של כ-90% מנפחה. לשם כך נאסף מאגר הקלטות של מזיגת מים לכוסות שונות, בוצע חילוף מאפיינים ונבחנו מספר מודלים של סיווג בינארי. המודל הסופי נבחר לפי שילוב בין ביצועי הסיווג, frame אקוסטיים מכל לבין יכולתו להפעיל עצירה בזמן מתאים ובטוח.

מטרות הניסוי:

- לאסוף מאגר הקלטות שמע מתויג של תהליכי מילוי כוסות מסוגים שונים.
- לחלץ מאפיינים אקוסטיים מכל frame הרגישים לשינוי ברמת המילוי.
- לאמן ולהשוות בין מספר מסווגים בינאריים לזיהוי מצב של כוס כמעט מלאה.
- להעריך את דיוק זמן העצירה של המערכת ביחס לנקודת היעד של 90% מילוי.

2. רקע תאורטי

2.1 הפיזיקה האקוסטית של מילוי כוס

כאשר מים נמזגים לתוך כוס, הצליל שנוצר משתנה לאורך תהליך המילוי. בתחילת המזיגה יש בכוס נפח אוויר גדול יחסית, ובהמשך, כאשר מפלס המים עולה, נפח האוויר שמעל המים קטן. שינוי זה משפיע על התגובה האקוסטית של הכוס ועל התדרים המופיעים באות השמע.

ניתן להתייחס לאוויר שנמצא מעל פני המים כאל חלל תהודה אקוסטי. כאשר עמודת האוויר מתקצרת, תדרי התהודה של המערכת נוטים לעלות. לכן, ככל שהכוס מתמלאת, ניתן לצפות לשינוי הדרגתי במאפיינים הספקטראליים של הצליל. שינוי זה מאפשר למערכת להסיק מידע על רמת המילוי של הכוס מתוך ההקלטה בלבד, ללא שימוש בחיישנים נוספים.

בקירוב, הקשר בין תדר התהודה לבין אורך עמודת האוויר יכול להיכתב כך:

$$f = \frac{c}{2L} \cdot \sqrt{\frac{1 + r^2 \cdot \pi}{2 \cdot r \cdot L}}$$

כאשר f הוא תדר התהודה, c היא מהירות הקול, L הוא אורך עמודת האוויר מעל המים, ו- r הוא רדיוס הכוס. לפי קשר זה, כאשר L קטן כתוצאה מעליית מפלס המים, תדר התהודה משתנה. עיקרון זה הוא הבסיס לכך שניתן לזהות את רמת המילוי באמצעות ניתוח אקוסטי.

2.2 Spectral Centroid כמדד לרמת המילוי

אחד המאפיינים המרכזיים שחולצו בקוד הוא Spectral Centroid. מאפיין זה מתאר את "מרכז הכובד" של הספקטרום, כלומר את המיקום הממוצע של האנרגיה בתחום התדר. אם רוב האנרגיה של האות נמצאת בתדרים נמוכים, ערך ה-Spectral Centroid יהיה נמוך יותר. אם האנרגיה עוברת לתדרים גבוהים יותר, ערך זה יעלה. ההגדרה של Spectral Centroid היא:

$$C = \frac{\sum_k f_k X_k}{\sum_k X_k}$$

כאשר f_k הם תחומי התדר, ו- X_k הם ערכי העוצמה המתאימים לכל תדר.

בפרויקט זה Spectral Centroid חשוב משום שהוא יכול לשקף את השינוי בצליל בזמן שהכוס מתמלאת. כאשר נפח האוויר בכוס קטן, התגובה האקוסטית של הכוס משתנה, ולעיתים מתקבלת עלייה במרכז הכובד התדרי. לכן מאפיין זה יכול לעזור למודל לזהות את המעבר מהשלבים הראשונים של המזיגה אל השלב שבו הכוס כמעט מלאה.

משמעות פיזיקלית ודומיננטיות של מקדם MFCC1:

מבחינה פיזיקלית, המקדם הראשון (MFCC1) מקודד את מעטפת הספקטרום (Spectral Envelope) ואת חלוקת האנרגיה הכוללת של אות השמע. כפי שמתואר בסעיף הפיזיקה האקוסטית, עליית מפלס הנוזל מקצרת את עמודת האוויר בכוס, המהווה חלל תהודה אקוסטי. התקצרות זו משנה באופן ישיר וגלובלי את תדרי התהודה (Formants), דבר שבא לידי ביטוי בשינוי "הצורה" הכוללת של גל הקול ולא רק בתדר בודד או במרכז כובד רגעי. בניחוח חשיבות המאפיינים של מערכת זו, דורג מאפיין ה-MFCC1 במקום הראשון בהשפעתו על החלטות מודל ה-LightGBM. עובדה זו מעניקה לו תוקף פיזיקלי משמעותי ומראה כי השינוי הרציף במעטפת הספקטרלית הגלובלית הוא האינדיקטור היציב והאמין ביותר לחיזוי רגע ההתקרבות לשפת הכוס.

2.3 מעבר מתחום הזמן לתחום התדר (Time-to-Frequency Transformation)

אות אודיו גולמי מיוצג בתחום הזמן כרצף של דגימות המתאר את שינויי המשרעת לאורך הזמן. עם זאת, מאפיינים אקוסטיים רבים, כגון תדרים דומיננטיים, אנרגיה ספקטרלית ומבנה התהודה של האות, אינם ניתנים לזיהוי בקלות בתחום הזמן בלבד. לכן, נהוג לבצע מעבר לתחום התדר באמצעות התמרת פורייה.

מכיוון שאותות אודיו הם אותות לא-סטציונריים שתכונותיהם משתנות לאורך הזמן, לא ניתן להסתפק בהתמרת פורייה אחת על כל האות. במקום זאת משתמשים ב-, Short-Time Fourier Transform (STFT) אשר מחלק את האות לחלונות זמן קצרים ומחשב עבור כל חלון את ספקטרום התדרים שלו. בדרך זו מתקבל ייצוג משולב של זמן ותדר המאפשר לעקוב אחר השינויים הספקטראליים לאורך ההקלטה.

לפני ביצוע ה-STFT, כל מסגרת זמן מוכפלת בפונקציית חלון, כגון חלון Hamming מטרת החלון היא לצמצם את תופעת זליגת הספקטרום, הנגרמת כתוצאה מחיתוך מלאכותי של האות בנקודות שאינן מחזוריות. שימוש בחלון Hamming מפחית את השפעת תופעה זו ומשפר את דיוק הייצוג הספקטראלי.

הצגת עוצמת התדרים כפונקציה של הזמן יוצרת ספקטרוגרמה, שהיא ייצוג חזותי של האות בתחום הזמן-תדר. הספקטרוגרמה מאפשרת לזהות שינויים בתוכן התדרי של האות לאורך זמן ומשמשת בסיס להבנת תהליך חילוף המאפיינים המתואר בפרקים הבאים.

2.4 Mel-Frequency Cepstral Coefficients (MFCCs)

MFCC הם מאפיינים נפוצים מאוד בעיבוד אותות שמע. הם מתארים את צורת הספקטרום של הצליל בצורה קומפקטית, תוך שימוש בסולם Mel שמנסה לייצג את האופן שבו האוזן האנושית תופסת תדרים. במקום להסתכל רק על תדר בודד, MFCC מתארים את המבנה הכללי של הצליל.

בקוד שלנו חולצו 13 מקדמי MFCC מכל frame. בנוסף, חושבו גם הנגזרות בזמן של מקדמים אלה: Δ ו- $\Delta\Delta$.

ה- Δ מתאר את קצב השינוי של המאפיין לאורך זמן, וה- $\Delta\Delta$ מתאר את השינוי בקצב השינוי. מאפיינים אלה חשובים משום שתהליך מילוי הכוס אינו מצב קבוע, אלא תהליך שמשתנה לאורך ההקלטה.

כן, שילוב של הכל מאפשר למודל ללמוד גם את צורת הצליל בכל רגע וגם את אופן השינוי של הצליל לאורך זמן. מידע זה עוזר לזהות את המעבר ממצב של כוס ריקה או חצי מלאה למצב שבו הכוס קרובה למילוי מלא.

הסברים עבור 5 המודלים הטובים ביותר שעבדו לנו:

בפרויקט נבחנו מספר מודלים של למידת מכונה לצורך סיווג בינארי של כל frame באות השמע כמצב "לא מלא" או "כמעט מלא". חמשת המודלים שהציגו את הביצועים הגבוהים ביותר לפי מדדי F1 ו-ROC-AUC היו LightGBM, XGBoost, Gradient Boosting, Random Forest ו-Extra Trees.

LightGBM:

הוא מודל מסוג Gradient Boosting המבוסס על בנייה הדרגתית של עצי החלטה. בכל שלב המודל מוסיף עץ חדש שמטרתו לתקן את השגיאות של העצים הקודמים. היתרון המרכזי של LightGBM הוא היכולת להתמודד היטב עם קשרים לא ליניאריים בין מאפיינים, וכן לעבוד בצורה יעילה גם כאשר קיימים הרבה מאפיינים. בפרויקט זה LightGBM נבחר כמודל הסופי משום שהגיע לביצועים הטובים ביותר, עם F1 של כ-0.735 ו-ROC-AUC של כ-0.968.

XGBoost

הוא גם מודל Boosting המבוסס על עצי החלטה, אך כולל מנגנוני רגולריזציה חזקים שמטרתם למנוע התאמת יתר לנתוני האימון. המודל בונה רצף של עצים, כאשר כל עץ חדש מתמקד בדוגמאות שבהן המודל הקודם טעה. בפרויקט זה XGBoost הגיע לביצועים גבוהים מאוד, אך היה מעט פחות טוב מ-LightGBM במדד הכולל.

Gradient Boosting

הוא מודל Boosting קלאסי, שבו עצי החלטה נבנים אחד אחרי השני וכל עץ מנסה לצמצם את השגיאה שנותרה מהעצים הקודמים. מודל זה מתאים לבעיות שבהן הקשר בין המאפיינים לבין התוצאה אינו ליניארי, כמו במקרה של אותות שמע בזמן מילוי כוס. בפרויקט זה הוא שימש גם כמודל ייחוס במחקר האבלציה, כדי לבדוק את תרומת קבוצות המאפיינים השונות.

Random Forest

הוא מודל המבוסס על אוסף גדול של עצי החלטה בלתי תלויים. כל עץ מאומן על תת-קבוצה שונה של הנתונים והמאפיינים, וההחלטה הסופית מתקבלת לפי הצבעה או ממוצע של כלל העצים. היתרון של Random Forest הוא יציבות גבוהה ועמידות יחסית לרעש, אך לעיתים הוא פחות מדויק ממודלי Boosting משום שכל העצים נבנים באופן עצמאי ואינם מתקנים זה את זה.


Extra Trees

דומה ל-Random Forest, אך מוסיף רמת אקראיות גבוהה יותר בבחירת נקודות הפיצול של העצים. אקראיות זו יכולה להפחית התאמת יתר

3. חומרים ושיטות

תרשים זרימה:

Audio Processing Pipeline



תרשים זרימה של תהליך עיבוד הנתונים במערכת. ההקלטות עוברות זיהוי אזור מציגה פעיל, חלוקה למסגרות זמן, חילוף 56 מאפיינים אקוסטיים, תיוג אוטומטי, אימון מודלים באמצעות GroupKFold Cross Validation ולבסוף הפקת החלטת עצירה.

3.1 איסוף נתונים

הקלטות השמע בוצעו באמצעות מיקרופון סטנדרטי בסביבה פנימית ומבוקרת. כל הקלטה מתעדת מזיגה בודדת מתחילתה ועד למניעת גלישת המים

פרמטר	ערך
סך הכל הקלטות	120
סוגי הכוס	8 סוגים (cup1-cup8)
מספר הקלטות לכוס	14-16
משך זמן הקלטה ממוצע	3.2-8.5 שניות
פורמט השמע	קצב דגימה מקורי, Wav
שיעור המחלקה החיובית (is_full=1)	10.3% מכלל החלונות בזמן (frames)

3.2 עיבוד מקדים

טרם חילוץ המאפיינים, בוצע שלב עיבוד מקדים במטרה לשפר את איכות האות ולהתמקד באזור הרלוונטי של תהליך המזיגה. תחילה בוצע צמצום רעש רקע באמצעות הספרייה Noisereduce, תוך שימוש ב-0.5 השניות הראשונות של כל הקלטה כפרופיל רעש. לאחר מכן בוצע חיתוך קצוות דינמי באמצעות הפונקציה (librosa.effects.split(top_db=40) אשר זיהתה את מקטע המזיגה הפעיל והסירה באופן אוטומטי את קטעי השקט שקדמו לתחילת המזיגה ואת קטעי השקט שהופיעו לאחר סיומה. כתוצאה מכך, כל תהליכי חילוץ המאפיינים שבוצעו לאחר מכן הופעלו על האות החתוך בלבד, המכיל את אירוע המזיגה עצמו.

```
reduced = nr.reduce_noise(y=data.astype(np.float32), sr=rate, y_noise=noise_clip)
intervals = librosa.effects.split(y, top_db=40)
y_active = y[intervals[0][0] : intervals[-1][1]]
```

קטע קוד 1 - צמצום רעש רקע וחיתוך קצוות דינמי מתוך

3.3 חילוץ המאפיינים

המאפיינים מחולצים ברמת חלון זמן (frame-per) באמצעות חלון האמינג (hamming window) באורך 50 מילי שניות עם צעד קפיצה (hop) של 25 מילי שניות.

חלק מהמאפיינים, כגון MFCC ו-Dominant Frequency, חושבו בתחום התדרים 1000–8000 Hz, מאחר שזהו תחום שבו נצפו שינויים משמעותיים בצליל המזיגה. מאפיינים ספקטראליים כלליים נוספים, כגון Spectral Centroid, Rolloff ו-Bandwidth, חושבו על האות החתוך לאחר שלב העיבוד המקדים.

Feature Group	Features	Count
MFCCs	Coefficients 1-13	13
Delta MFCCs	1st derivative of MFCCs	13
Delta-Delta MFCCs	2nd derivative of MFCCs	13
Spectral	Centroid, Rolloff, Bandwidth, ZCR, RMS	5
Dominant Frequency	Peak freq in 1-8kHz band	1
Delta Centroid	1st and 2nd derivative	2
Spectral Shape	Skewness, Kurtosis	2
Spectral Contrast	7 sub-band contrast bands	7
Total		56

```
stft = np.abs(librosa.stft(y_active, n_fft=frame_len, hop_length=hop_len))
freq_mask = (freqs >= 1000) & (freqs <= 8000)
stft_bound = stft[freq_mask, :]
```

קטע קוד 2 - חישוב STFT עם הגבלת תחום התדרים ל-1000–8000.

3.4 תיוג נתונים

כל חלון זמן (frame) מתויג כ $is_full=1$ אם חותמת הזמן (timestamp) שלו מקיימת את התנאי:

$$time_sec \geq 0.90 \cdot t_{actual_full}$$

כאשר t_{actual_full} הוא המשך הכולל של פרק המזיגה הפעילה. סף זה של 90% מגדיר את נקודת העצירה הראויה, תוך יצירת איזון בין מילוי מקסימלי של הכוס לבין סיכון לגלישת מים.

```
df["is_full"] = (df["time_sec"] >= df["t_actual_full"] * 0.90).astype(int)
```

קטע קוד 3-labeling.

3.5 ארכיטקטורת המודל

נבנתה והוערכה מערכת סיווג בינארית (Binary Classifier Pipeline) באמצעות cross-validation מסוג fold-5 GroupKFOLD. החלוקה לקבוצות בוצעה לפי מזהה ההקלטה כדי למנוע דליפת מידע (Data Leakage) בין קבוצות האימון והבדיקה.

המודלים שנבחנו:

- Random Forest (class_weight=balanced)
- Gradient Boosting (tuned via RandomizedSearchCV)
- LightGBM (class_weight=balanced, tuned via RandomizedSearchCV, N_ITER=10)
- AdaBoost (SAMME algorithm)
- Logistic Regression (class_weight=balanced, scaled via StandardScaler)
- Extra Trees (class_weight=balanced)
- HistGradientBoosting (class_weight=balanced)
- SVC (kernel='rbf', class_weight=balanced, scaled via StandardScaler)
- KNN (scaled via StandardScaler)
- XGBoost (tree_method='hist', scale_pos_weight=9)

מנגנון העצירה (stop trigger) נקבע באמצעות הפעלת ממוצע נע סביבתי (causal rolling average) בחלון של 10 פריימים על פלט ההסתברות של המודל לכל פריימים.

העצירה מופעלת כאשר ההסתברות המחולקת עוברת את סף ההחלטה של 0.35 (threshold = 0.35).

הבחירה בסך נמוך יחסית נעשתה במכוון מכון שהמערכת מעדיפה לעצור מעט מוקדם יותר מאשר להגיב מאוחר ולגרום לגלישה של המים.

3.6 כיוון מודל

3.6.1 מוטיבציה והגדרת הבעיה

מטרת המחקר היא לזהות באמצעות אות השמע את השלב שבו הכוס מתקרבת למצב מלא, לצורך כך הגדרנו את הבעיה כבעיית סיווג בינארית, שבה כל מסגרת זמן מסווגת לאחת משתי המחלקות - "לא מלא", "מלא".

הדוגמאות סומנו כמחלקה חיובית ($is_full=1$) כאשר זמן ההקלטה הגיע ל 90% או יותר מזמן המילוי הכולל של הכוס, כלומר רק 10 אחוז אחרונים של התהליך הוגדרו כ"מלא". יתר הדוגמאות סומנו כמחלקה שלילית ($is_full=0$).

מכיוון שרק כ 10 מהדוגמאות שייכות למחלקה החיובית, מאגר הנתונים סובל מ חוסר איזון בין המחלקות (Class imbalance). מצב זה עלול לגרום למודל להעדיף את המחלקה השכיחה ולהימנע מללמוד את המאפיינים של המחלקה הנדירה. כדי להתמודד עם בעיה זו אנחנו עושים שימוש במנגנון איזון מחלקות במהלך האימון. במודלים המבוססי עצים נעשה שימוש בפרמטר הנקרא `class_weight = "balanced"`, ובמודל XGBoost נעשה שימוש בפרמטר `scale_pos_weight = 9`, בהתאם ליחס המשוער של 90:10 בין המחלקות.

מנגנון האיזון - מעניק משקל גבוה יותר עבור טעויות על המחלקה הנדירה, ככה שהמודל לא יתעלם ממנה במהלך האימון.

3.6.2 אסטרטגיית Cross-Validation

לצורך הערכה אמינה ובלתי מוטת של ביצועי המודלים נעשה שימוש ב GroupKFold Cross Validation, בכל חלוקה הוגדרה קבוצה על פי שילוב של סוג הכוס וקובץ ההקלטה, ככה שכל הדגימות שהופקו מאותה הקלטה נשמרו יחד. גישה זו מבטיחה כי כל הקלטה תופיע במלואה בקבוצת האימון או במלואה בקבוצת הבדיקה, ובנוסף זה מונע זליגת מידע בין הקבוצות. המנגנון הזה כל כך חשוב פה בגלל שפריימים עוקבים מאותה הקלטה חולקים מאפיינים דומים מאוד ולכן הם בלתי תלויים סטטיסטית, חלוקה אקראית ברמת הפריים הייתה עלולה להוביל להערכת ביצועים טובה מדי.

3.6.3 בחירת היפר פרמטרים Hyperparameter Search

בשלב הראשון של המחקר בוצע תהליך כוונת היפר פרמטרים עבור עשרה מודלים קלאסיים של למידת מכונה באמצעות RandomizedSearchCV. עבור כל מודל נבדקו עשרה שילובים שונים של פרמטרים, כאשר קריטריון האופטימיזציה היה ציון F1, שחושב באמצעות ה GroupKFold.

לכל משפחת מודלים הוגדר מרחב חיפוש ייעודי הכולל את ההיפר פרמטרים המשפיעים ביותר על ביצועיה. לדוגמה עבור מודלי ה Boosting נבחנו פרמטרים כגון קצב הלמידה ועומק העצים, ואילו עבור מודל SVC נבחנו הפרמטרים C, Gama.

במודלים המבוססים על מרחקים או רגרסיה ליניארית (SVC, KNN ו- Logistic Regression) שולב StandardScaler כחלק מצינור העיבוד (Pipeline), כדי להבטיח שכל המאפיינים יהיו באותה סקאלה. לאחר השלמת החיפוש נבחרה עבור כל מודל הקונפיגורציה בעלת ציון ה-F1 הגבוה ביותר, והיא שימשה להערכה הסופית בשלב השני של המחקר.

Model	Hyperparameters & Search Space
Random Forest	n_estimators: 100, 200, 400, 600 max_depth: None, 10, 20, 30 min_samples_leaf: 1, 2, 4 max_features: "sqrt", "log2", 0.5
Extra Trees	n_estimators: 100, 200, 400, 600 max_depth: None, 10, 20, 30 min_samples_leaf: 1, 2, 4 max_features: "sqrt", "log2", 0.5
Gradient Boosting	n_estimators: 100, 200, 400 learning_rate: 0.01, 0.05, 0.1, 0.2 max_depth: 3, 5, 7 subsample: 0.7, 0.8, 1.0 min_samples_leaf: 1, 5, 10
HistGradientBoosting	max_iter: 100, 200, 400 learning_rate: 0.01, 0.05, 0.1, 0.2 max_depth: None, 5, 10, 15 min_samples_leaf: 10, 20, 40 l2_regularization: 0.0, 0.1, 1.0
XGBoost	n_estimators: 100, 200, 400 learning_rate: 0.01, 0.05, 0.1, 0.2 max_depth: 3, 5, 7, 9 subsample: 0.7, 0.8, 1.0 colsample_bytree: 0.6, 0.8, 1.0 reg_alpha: 0, 0.1, 1.0 reg_lambda: 1, 5, 10
LightGBM	n_estimators: 100, 200, 400 learning_rate: 0.01, 0.05, 0.1, 0.2 num_leaves: 31, 63, 127 max_depth: -1, 5, 10 subsample: 0.7, 0.8, 1.0 colsample_bytree: 0.6, 0.8, 1.0 reg_alpha: 0, 0.1, 1.0 reg_lambda: 0, 1.0, 5.0
AdaBoost	n_estimators: 50, 100, 200 learning_rate: 0.01, 0.05, 0.1, 0.5, 1.0
SVC *	C: 0.1, 1, 10, 50, 100 gamma: "scale", "auto", 0.001, 0.01

KNN *	n_neighbors: 3, 5, 10, 15, 20, 30 weights: "uniform", "distance" metric: "euclidean", "manhattan"
Logistic Regression *	c: 0.001, 0.01, 0.1, 1.0, 10.0 penalty: "l2" solver: "lbfgs", "saga"

3.6.4 הערכה מלאה עם החלקה זמנית

בשלב השני של המחקר הוערכו המודלים בתנאי הפעלה המדמים מערכת אמת. תחילה חושבו הסתברויות הסיווג עבור כל מסגרת זמן, ולאחר מכן החלה החלקה זמנית באמצעות ממוצע נע סיבתי (Causal Rolling Average) בגודל חלון של 10 מסגרות, מנגנון זה נועד להפחית את השפעת הרעש ולייצב את החלטת העצירה.

פקודת עצירה הופעלה ברגע שבו הסתברות המוחלקת חצתה את סף ההחלטה שנקבע ל 0.35. עבור כל הקלטה חושבה שגיאת זמן העצירה: $\Delta t = t_{pred_stop} - (0.9 \cdot t_{actual_full})$

ערכים שליליים מייצגים עצירה מוקדמת ובטוחה, בעוד שערכים חיוביים מייצגים עצירה מאוחרת העלולה להוביל לגלישת מים. בנוסף לדיוקי הסיווג המקובלים (F1, Recall, Precision, Roc, AUC) נותח גם זמן העצירה הממוצע, סטיית תקן של שגיאת הזמן, ומספר אירועי העצירה שסווגו כמוקדמים, מאוחרים או ככאלה שבהם לא התקבלה כלל החלטה.

```
return t_pred_stop - (t_actual_full * FULL_THRESHOLD)
```

קטע קוד 3 .

3.6.5 קריטריון בחירת המודל

במקום לבחור את המודל רק לפי ערך ה-F1 הגבוה ביותר, נעשה שימוש במדד בחירה משולב. הסיבה לכך היא שבבעיה זו לא מספיק שהמודל יסווג נכון frames בודדים, אלא חשוב גם שהוא יפעיל את העצירה בזמן בטוח. בפרויקט של מניעת גלישת מים, עצירה מאוחרת עלולה לגרום לגלישה, ולכן יש להעניש מודלים שנוטים להפעיל את העצירה מאוחר מדי.

מדד הבחירה חושב לפי הנוסחה

$$score = F1 - 0.1 \times late_rate - 0.02 \times |\Delta t_mean|$$

כאשר (F1) הוא מדד איכות הסיווג, (late_rate) הוא שיעור המקרים שבהם המודל עצר מאוחר מדי, ו- $|Delta_mean|$ הוא הערך המוחלט של שגיאת זמן העצירה הממוצעת.

באמצעות מדד זה, מודל שמגיע ל-F1 גבוה אך גורם להרבה עצירות מאוחרות יקבל ציון נמוך יותר. בצורה זו בחירת המודל מתחשבת גם בביצועי הסיווג וגם בדרישת הבטיחות של המערכת. המשקלים 0.1 ו-0.02 נבחרו כדי לתת חשיבות גבוהה יותר לעצירה מאוחרת, משום שעצירה מוקדמת מעט עדיפה על מצב שבו הכוס גולשת.

```
def score(k):
    late_rate = r["Late"] / total
    dt_penalty = abs(r["Delta_t_mean"])
    return r["F1"] - 0.1 * late_rate - 0.02 * dt_penalty
```

קטע קוד 4 .

3.6.6 בדיקת הסרת מאפיינים - Ablation Study

כדי לבדוק את התרומה של קבוצות מאפיינים שונות, בוצעה בדיקת ablation study. בבדיקה זו מאמנים את המודל מספר פעמים, כאשר בכל פעם מסירים חלק אחר מהמאפיינים, ובודקים כיצד ההסרה משפיעה על הביצועים.

בפרויקט נבדקו שלוש קבוצות מאפיינים:

1. כל 56 המאפיינים - סט המאפיינים המלא.
2. ללא מאפייני delta ו- delta-delta - כלומר ללא הנגזרות הזמניות.
3. MFCC + מאפיינים בסיסיים בלבד סט מצומצם יותר של מאפיינים.

תוצאות הבדיקה הראו שכאשר מסירים את מאפייני ה-delta וה-delta-delta, ערך ה-F1 יורד. בנוסף, כאשר משתמשים רק ב-MFCC ובמאפיינים בסיסיים, מתקבלת ירידה נוספת בביצועים. מכאן ניתן להסיק שהנגזרות הזמניות הן חלק חשוב מהמודל, משום שהן מתארות את השינוי של הצליל לאורך זמן ולא רק את מצב הצליל ברגע מסוים.

מסקנה זו מתאימה לאופי הבעיה: מילוי כוס הוא תהליך דינמי, ולכן למודל חשוב לדעת לא רק אילו תדרים מופיעים בכל frame, אלא גם כיצד המאפיינים האקוסטיים משתנים לאורך ההקלטה. לכן בקוד הסופי נשמר סט המאפיינים המלא, הכולל את כל 56 המאפיינים.

3.6.7 המודל המנצח ואימון סופי

לאחר השוואת המודלים לפי מדד הבחירה המשולב, המודל שנבחר כמודל הסופי הוא LightGBM. מודל זה הציג את הביצועים הטובים ביותר מבין המודלים שנבדקו, עם F1 של 0.735 ו-AUC-ROC של כ-0.968.

בנוסף, שגיאת זמן העצירה הממוצעת הייתה כ-1.00 שניות, כלומר בממוצע המודל הפעיל את העצירה לפני נקודת היעד של 90% מילוי.

תוצאה זו נחשבת מתאימה למטרת המערכת, משום שבמערכת למניעת גלישה עדיף לעצור מעט מוקדם מאשר לעצור מאוחר מדי. עצירה מוקדמת יוצרת מרווח ביטחון, בעוד שעצירה מאוחרת עלולה לגרום לגלישת מים מהכוס.

באופן כללי, משפחת מודלי Gradient Boosting, הכוללת את XGBoost, LightGBM ו-Gradient Boosting, הציגה ביצועים טובים יותר מרוב המודלים האחרים. לעומת זאת, מודלים פשוטים יותר כמו Logistic Regression ו-AdaBoost הגיעו לביצועים נמוכים יותר, כנראה משום שהם מתקשים לתאר קשרים לא ליניאריים מורכבים בין מאפייני השמע לבין מצב המילוי של הכוס. לאחר בחירת LightGBM כמודל הסופי, הוא אומן מחדש על כל מאגר הנתונים ונשמר לשימוש עתידי בקובץ:

models/best_model.pkl

בנוסף, נוצר גרף חשיבות מאפיינים עבור המודל. גרף זה מראה אילו מאפיינים השפיעו בצורה המשמעותית ביותר על החלטות המודל. לפי התוצאות, מאפיינים כמו Spectral centroid, מקדמי MFCC ונגזרותיהם בזמן היו בין המאפיינים החשובים ביותר.

4. תוצאות

4.1 סטטיסטיקות של מערך הנתונים

ממד	ערך	הערות
סך הכל פריימים	29,769	על פני כל 120 ההקלטות (מייצג את סך פריימי הזמן לאחר הפעלת מנגנון החיתוך הדינמי לאיתור המזיגה).
מאפיינים לפריימים (features)	56	ראו סעיף 3.3.
מחלקה חיובית (is_full=1)	10.3%	חוסר איזון צפוי במחלקות.
קבוצות (הקלטות)	120	משמש עבור אימות צולב (GroupKFold CV).

4.2 ביצועי המודלים

הסבר מושגים:

Precision - מתוך כל העצירות שבוצעו, כמה היו נכונות.

F1 - איזון בין Precision ו-Recall.

Recall - מתוך כל המצבים שבהם היה צריך לעצור, כמה זהו

Roc-AUC - מודד את יכולת ההפרדה הכללית של המודל.


Mean Δt - השגיאה הממוצעת בזמן העצירה.

Std Δt - עד כמה זמני העצירה יציבים.


Model Comparison (5-fold GroupKFold CV) — best: LightGBM (highlighted)

	Model	Precision	Recall	F1	AUC-ROC	Mean Delta-t (s)	Early	Late	Never
	LightGBM	0.721	0.751	0.735	0.968	-1.00	80	40	0
	XGBoost	0.691	0.778	0.731	0.963	-1.74	92	28	0
	Gradient Boosting	0.760	0.674	0.712	0.967	-0.69	69	51	0
	Random Forest	0.678	0.731	0.703	0.947	-1.90	87	33	0
	Extra Trees	0.683	0.724	0.702	0.949	-1.76	84	36	0
	HistGradientBoosting	0.609	0.805	0.692	0.955	-2.19	107	13	0
	KNN	0.736	0.611	0.666	0.947	-0.41	65	55	0
	SVC	0.681	0.650	0.664	0.957	-2.59	90	29	1
	Logistic Regression	0.209	0.804	0.331	0.820	-5.26	120	0	0
	AdaBoost	0.082	0.749	0.149	0.682	-5.54	120	0	0

השוואת ביצועי המודלים באמצעות 5-Fold GroupKFold CV. מודל LightGBM השיג את ציון ה-F1 הגבוה ביותר (0.735) ואת ערך ה-AUC-ROC הגבוה ביותר (0.968), ולכן נבחר כמודל הסופי.



איור 4.1 - השוואת מודלים לפי מדד $F1$, מדד AUC-ROC, וכמות עצירות מאוחרות (late stops). המודל המוביל הוא LightGBM (בירוק).



איור 4.2 מטריצת הבלבול של המודל הנבחר (LightGBM) במסגרת 5-Fold Cross Validation. ניתן לראות כי רוב הדגימות סווגו נכונה, עם איזון טוב בין Precision (0.721) ל-Recall (0.751), שהוביל לציון $F1$ של 0.735.

4.3 דיוק זמני המודל המוביל: (LightGBM)

פרשנות	ערך	מדד
השיהוי הממוצע (Latency) לאחר נקודת המילוי האמיתית.	-0.997 s $\approx$ -1 s	ממוצע שגיאת זמן (delta-t mean)
פיזור השגיאה בין סוגי הכוסות וההקלטות השונות.	2.056 s	(Std Delta-t) סטיית תקן
אחוז המקרים בהם המערכת עצרה לפני היעד (מצב בטוח למניעת גלישה).	~67%	עצירות מוקדמות (Early triggers)
אחוז המקרים בהם המערכת עצרה אחרי היעד (אך לפני גלישה בפועל).	33%	עצירות מאוחרות (Late triggers)
מספר המקרים שבהם המודל לא חצה את סף ההסתברות לעצירה באף שלב בהקלטה.	0	(Never triggered) לא הופעל מעולם


זמן הפעולה בפועל של המערכת: כפי שניתן לראות במדד ה- Δt mean, המערכת פועלת בממוצע כ-0.997 שניות (כשנייה אחת) לפני הגעה ליעד ה-90%. זמן זה נבחר וכויל בקפידה באמצעות סף ההחלטה (Threshold = 0.35) כדי להבטיח מרווח בטיחות אופטימלי שמונע גלישת מים, תוך ניצול מקסימלי של נפח הכוס.

4.4 תוצאות חיזוי לדוגמה (Sample Prediction Results)


Recording	t_actual_full	Target 90%	Model fires	Delta-t
cup3 / 20260602-091026	2.38 s	2.14 s	2.22 s	+0.08 s
cup4 / 20260602-090456	4.72 s	4.25 s	4.32 s	+0.07 s
cup6 / 20260602-084844	7.37 s	6.63 s	6.72 s	+0.09 s
cup8 / 20260602-083604	7.24 s	6.52 s	6.62 s	+0.10 s
cup8 / 20260602-083924	9.20 s	8.28 s	8.35 s	+0.07 s

הטבלה מציגה דוגמאות שבהן המודל עצר קרוב מאוד ליעד ה-90%. אף שבדוגמאות אלו ערך Δt חיובי, כלומר העצירה התרחשה מעט לאחר יעד ה-90%, הסטייה קטנה מאוד ונעה סביב עשיריות שנייה בלבד. בתוצאות הכוללות, המודל נטה בממוצע לעצור מוקדם יותר, כפי שניתן לראות בערך Δt_{mean} .


דוגמא שורה 5 מתוך הטבלה העליונה - כוס 8



איור 4.3 - כוס 8: מפלס המילוי לאורך זמן. המודל מופעל 0.07 שניות אחרי יעד ה-90%



איור 4.4 - כוס 8: הסתברות מוחלקת. המודל מופעל 0.07 שניות אחרי יעד ה-90% — סטייה זניחה.



איור 4.5 - כוס 8: ספקטרוגרמה עם צנטרואיד ספקטרלי. הצנטרואיד נשאר גבוה (~14-16 קילו-הרץ) ברוב ההקלטה וצונח בחדות סביב 8.3 שנייה, כשהתמלאות הכוס מחניקה את התדרים הגבוהים – מה שמפעיל את המודל בשנייה 8.35, כ-0.07 שניות בלבד לאחר יעד ה-90%

4.5 חשיבות מאפיינים (Feature Importance)

הסברים של 5 הפיצ'רים הטובים ביותר של המודל הנבחר:

לאחר בחירת LightGBM כמודל הסופי של המערכת, בוצע ניתוח חשיבות מאפיינים במטרה להבין אילו מאפיינים תרמו בצורה המשמעותית ביותר להחלטות המודל. ניתוח זה חשוב משום שהוא מאפשר לפרש את אופן הפעולה של המודל, ולא רק לבחון את הביצועים המספריים שלו. חמשת המאפיינים החשובים ביותר שנמצאו עבור מודל LightGBM הם: `mfcc1`, `centroid_delta`, `rms`, `delta_mfcc1` ו-`delta_mfcc2`.

mfcc1

הוא מקדם ה-MFCC הראשון. מאפיין זה מתאר את המבנה הספקטרלי הכללי של אות השמע, כלומר את האופן שבו האנרגיה של הצליל מתפלגת בין תחומי התדר השונים. בזמן מילוי הכוס, הצליל משתנה כתוצאה מהשינוי בנפח האוויר ומהתגובה האקוסטית של הכוס. לכן `mfcc1` מספק למודל מידע חשוב על צורת הצליל בכל `frame`. העובדה שמאפיין זה דורג כמאפיין החשוב ביותר מצביעה על כך שהשינוי הכללי במבנה הספקטרלי של הצליל הוא גורם משמעותי בזיהוי מצב המילוי.

centroid_delta

מתאר את קצב השינוי של ה-Spectral Centroid לאורך זמן. ה-Spectral Centroid עצמו מייצג את מרכז הכובד של הספקטרום, כלומר האם האנרגיה של הצליל מרוכזת יותר בתדרים נמוכים או גבוהים. לעומת זאת, `centroid_delta` אינו מתאר רק את הערך הרגעי של המרכז הספקטרלי, אלא את האופן שבו הוא משתנה בין `frame` אחד לאחר. מאפיין זה חשוב במיוחד בפרויקט זה משום שמילוי כוס הוא תהליך דינמי, ולכן שינוי במרכז התדרים יכול להעיד על התקרבות הכוס למצב מלא.

rms

מייצג את עוצמת האנרגיה של אות השמע בכל `frame`. ערך RMS גבוה מעיד על אות חזק יותר, וערך נמוך מעיד על אות חלש יותר. במהלך המזיגה, עוצמת הצליל עשויה להשתנות בהתאם לגובה המים, לאופן פגיעת זרם המים בכוס ולשינויי התהודה של הכלי. לכן `rms` מספק למודל מידע משלים שאינו מתמקד ישירות בתדרים, אלא בעוצמה הכוללת של הצליל. שילוב מידע זה עם מאפיינים ספקטראליים מאפשר למודל לקבל תמונה רחבה יותר של מצב המזיגה.

delta_mfcc1

מתאר את קצב השינוי של מקדם MFCC הראשון לאורך זמן. בעוד ש-`mfcc1` מתאר את מבנה הספקטרום ברגע מסוים, `delta_mfcc1` מתאר כיצד אותו מבנה משתנה לאורך רצף הפריימים. מאפיין זה חשוב משום שהמודל לא צריך להסתמך רק על תמונת מצב רגעית של הצליל, אלא גם על מגמת השינוי שלו. העובדה ש-`delta_mfcc1` נמצא בין חמשת המאפיינים החשובים ביותר מחזקת את המסקנה שהדינמיקה של הצליל היא חלק מרכזי בזיהוי רמת המילוי.


delta_mfcc2

מתאר את קצב השינוי של מקדם MFCC השני לאורך זמן. בדומה ל-`delta_mfcc1`, גם מאפיין זה מוסיף מידע דינמי על שינויי הספקטרום במהלך המזיגה. הוא מאפשר למודל לזהות שינויים עדינים נוספים בצורת הצליל, שלא בהכרח נראים מתוך ערכי ה-MFCC הרגועים בלבד. לכן `delta_mfcc2` תורם ליכולת של המודל לזהות את המעבר ההדרגתי ממצב של כוס שאינה מלאה למצב שבו הכוס קרובה למילוי מלא.

לסיכום, חמשת המאפיינים החשובים ביותר של מודל LightGBM מראים שהמודל מסתמך גם על מבנה הצליל בכל רגע וגם על אופן השינוי של הצליל לאורך זמן. מאפיינים כמו `rms` ו-`mfcc1` מתארים את מצב האות בכל פריים, בעוד שמאפיינים כמו `delta_mfcc1`, `centroid_delta` ו-`delta_mfcc2` מתארים את הדינמיקה של האות לאורך תהליך המזיגה. ממצא זה מתאים לאופי הפיזיקלי של הבעיה, משום שמילוי כוס הוא תהליך רציף שבו מפלס המים עולה בהדרגה ומשנה את התגובה האקוסטית של הכוס.

ניתוח חשיבות המאפיינים מתוך המודל המוביל (LightGBM) חושף את הדירוג הבא עבור המאפיינים התורמים ביותר להחלטת העצירה של המערכת:

מאפיין (Feature)	דירוג (Rank)	משמעות אקוסטית / תרומה למודל
mfcc1	1	מקודד את חלוקת האנרגיה הספקטרלית הכוללת.
delta_centroid	2	קצב השינוי של מרכז הכובד — מזהה את המעבר (ההאצה) לקראת הגעה ליעד המילוי.
rms	3	מייצג את עוצמת האנרגיה של האות.
delta_mfcc1	4	מתאר את קצב השינוי של MFCC 1.
delta_mfcc2	5	מתאר את קצב השינוי של MFCC 2.



איור 4.6 - 20 המאפיינים החשובים ביותר עבור מודל LightGBM. מאפייני ה-delta וה-delta² (נגזרות בזמן) שולטים בדירוג, עובדה המאמת את ממצאי מחקר האבלציה (Ablation study).

5. דיון

5.1 פירוש תוצאות

תוצאות הניסוי מצביעות על יכולת זיהוי יציבה ואמינה של מצב המילוי בכל שמונת סוגי הכוסות שנבדקו. זמן העצירה הממוצע התקבל כ-1 שנייה לפני נקודת היעד שהוגדרה כ-90% מזמן המילוי הכולל. התנהגות זו תואמת את מטרת התכנון של המערכת, אשר מעדיפה הפעלת עצירה מוקדמת על פני הסיכון לעצירה מאוחרת העלולה לגרום לגלישת נזל. הבחירה בסף החלטה נמוך יחסית (0.35) נועדה במכוון לספק מרווח בטיחות ולצמצם את הסיכון למילוי יתר.

ניתוח חשיבות המאפיינים הראה כי המאפיין MFCC 1 היה המשפיע ביותר על ביצועי מודל ה-LightGBM. מאפיין זה מתאר את המבנה הספקטראלי הכללי של האות האקוסטי, ולכן מספק מידע משמעותי על השינויים המתרחשים במהלך תהליך מילוי הכוס. בנוסף, נמצאו גם המאפיינים Delta Centroid ו-RMS כבעלי חשיבות גבוהה, דבר המצביע על כך שהמודל מסתמך הן על התפלגות התדרים של הצליל והן על השינויים הדינמיים והאנרגטיים המתרחשים לאורך תהליך המזיגה. ממצא מעניין נוסף הוא שחלק ניכר מהמאפיינים החשובים ביותר במודל הם מאפייני Delta, כגון Delta MFCC 1, Delta Centroid 1, ו-Delta MFCC 2.

עובדה זו מצביעה על כך שהמודל אינו מסתמך רק על ערכי התדירים עצמם, אלא גם על קצב השינוי שלהם לאורך הזמן. תוצאה זו תואמת את אופיו הדינמי של תהליך המזיגה, שבו השינויים האקוסטיים הנוצרים במהלך עליית מפלס המים מספקים מידע משמעותי לצורך קבלת החלטת העצירה.

ההתאמה בין המאפיינים האקוסטיים שנמדדו לבין ביצועי המודל מחזקת את המסקנה כי ניתן לזהות את מצב מילוי הכוס באמצעות ניתוח אות האודיו בלבד, ללא צורך בחייושני גובה, משקל או מערכות ראייה ממוחשבת.

5.2 השפעת סף ההחלטה

סף ההחלטה נקבע לערך 0.35 במטרה להעדיף עצירה מוקדמת של תהליך המילוי. כאשר ההסתברות המחושבת על ידי המודל עוברת ערך זה, מופעל מנגנון העצירה. תוצאות הניסוי הראו כי בערך 67% מההקלטות הובילו לעצירה לפני נקודת היעד שהוגדרה כ-90% מזמן המילוי הכולל. משמעות הדבר היא שבמרבית המקרים המערכת מספקת מרווח בטיחות המקטין את הסיכון לגלישת נזל.

עם זאת, ערך הסף משפיע באופן ישיר על התנהגות המערכת. הגדלת הסף הייתה גורמת למערכת להמתין לביטחון גבוה יותר לפני הפעלת העצירה, ובכך להפחית את מספר העצירות המוקדמות. מנגד, פעולה זו הייתה עלולה להגדיל את מספר העצירות המאוחרות ואת הסיכון לגלישה. לעומת זאת, הקטנת הסף הייתה מובילה לעצירות מוקדמות יותר ולבטיחות גבוהה יותר, אך על חשבון ניצול מלא של נפח הכוס.

לפיכך, סף ההחלטה מהווה פשרה (Trade-off) בין בטיחות לבין דיוק המילוי, וניתן להתאימו בהתאם לדרישות היישום. במערכות שבהן מניעת גלישה היא השיקול המרכזי, ניתן לבחור סף נמוך יותר, בעוד שבמערכות שבהן נדרש מילוי מדויק יותר ניתן להעלות את הסף בהתאם.

5.3 מגבלות

למחקר מספר מגבלות שיש להביא בחשבון בעת פרשנות התוצאות:

- ראשית, אחוז המילוי חושב באופן ליניארי לאורך משך ההקלטה, תוך הנחה שקצב זרימת המים קבוע. במקרים שבהם קצב הזרימה משתנה במהלך המילוי, עלולות להיווצר שגיאות בתיוג הדוגמאות.
- הנתונים נאספו בסביבה מבוקרת ושקטה יחסית. רעשי רקע, שינוי במיקום המיקרופון או קיומם של מקורות קול נוספים עשויים להשפיע על ביצועי המערכת ולהפחית את דיוק הזיהוי.
- גאומטריית הכוס משפיעה באופן משמעותי על המאפיינים האקוסטיים של הצליל המופק במהלך המילוי. לפיכך, ביצועי המערכת עבור סוגי כוסות שלא הופיעו בנתוני האימון עשויים להיות נמוכים יותר, וייתכן שיידרש אימון נוסף או תהליך התאמה ייעודי.

- המימוש הנוכחי מבוסס על חילוץ מאפיינים לא מקוון (Offline Feature Extraction), שבו עיבוד האות מתבצע לאחר סיום ההקלטה. לצורך פריסה במערכת זמן אמת יהיה צורך בפיתוח מנגנון לחילוץ מאפיינים ועיבוד נתונים באופן רציף בזמן אמת.

5.4 סיכום מחקר האבלציה

בוצע מחקר אבלציה (Ablation Study) במטרה להעריך את תרומתן של קבוצות המאפיינים השונות לביצועי המודל. תוצאות הניסוי הראו כי הסרת מאפייני Delta ו-Delta-Delta הובילה לירידה של כ-15.6% בציון ה-F1 (מ-0.693 ל-0.585). ממצא זה מצביע על חשיבותם של מאפיינים אלו בייצוג הדינמיקה הזמנית של האות האקוסטי במהלך תהליך מילוי הכוס.

בנוסף, שימוש במאפייני MFCC ובמאפיינים ספקטראליים בסיסיים בלבד, ללא Delta, Delta-Delta ו-Spectral Contrast, הוביל לירידה של כ-17.2% בציון ה-F1 (מ-0.693 ל-0.573). תוצאה זו מדגישה כי המידע הסטטי לבדו אינו מספיק לצורך זיהוי מדויק של מצב המילוי.

לבסוף, נמצא כי סט המאפיינים המלא, הכולל 56 מאפיינים, השיג באופן עקבי את הביצועים הטובים ביותר בהשוואה לכל תתי-הקבוצות שנבדקו. ממצא זה מצדיק את הכללת כלל המאפיינים במודל הסופי ומעיד כי כל קבוצת מאפיינים תורמת מידע משלים לתהליך הסיווג.

יש לציין כי מחקר האבלציה בוצע באמצעות מודל Gradient Boosting, אשר שימש כמודל ייחוס (Reference Model) קבוע לאורך כל הניסויים. הבחירה במודל זה נועדה לבדוד את השפעת קבוצות המאפיינים השונות על ביצועי הסיווג, מבלי לערב שינויים הנובעים מהחלפת המודל עצמו. לפיכך, ערך הבסיס של $F1 = 0.693$ המופיע בניתוח האבלציה מייצג את ביצועי מודל Gradient Boosting עם סט המאפיינים המלא, ואינו מייצג את הביצוע הטוב ביותר שהושג במחקר. מודל LightGBM, אשר נבחר כמודל הסופי של המערכת, השיג ביצועים גבוהים יותר עם ציון $F1$ של כ-0.735.

Experiment	Features	F1	AUC	Δt mean	$\Delta F1$ vs. full
All features (baseline)	56	0.693	0.957	-0.93 s	—
No delta / delta ²	28	0.585	0.932	-2.20 s	-15.6%
MFCC + basic only	19	0.573	0.931	-2.38 s	-17.2%

6. מסקנות

מהניסוי שבוצע ניתן להסיק את המסקנות הבאות:

- ניתן להשתמש באותות שמע בלבד כדי לזהות את שלב המילוי של כוס, ללא צורך בחיישני משקל, מצלמה או חיישן מרחק.
- המאפיינים הספקטראליים של הצליל משתנים לאורך תהליך המזיגה, ולכן הם מספקים מידע שימושי על רמת המילוי של הכוס.

- מאפיינים כמו spectral centroid, מקדמי MFCC והנגזרות הזמניות שלהם נמצאו כמאפיינים משמעותיים עבור המודל, משום שהם מתארים גם את מבנה הצליל וגם את אופן השינוי שלו לאורך זמן.
- לאחר השוואה בין מספר מודלים, המודל שנבחר כמודל הסופי הוא LightGBM. לפי תוצאות הקוד, המודל הגיע ל-F1 של כ-0.735 ול-AUC-ROC של כ-0.968.
- שגיאת זמן העצירה הממוצעת של LightGBM הייתה כ-1.00 שניות, כלומר המודל נטה לעצור לפני נקודת היעד של 90% מילוי. בפרויקט זה עצירה מוקדמת מעט עדיפה על עצירה מאוחרת, משום שהיא מקטינה את הסיכון לגלישת מים.
- שימוש בסף החלטה של 0.35 יחד עם החלקה זמנית בעזרת causal rolling average בגודל 10 frames סיפק מנגנון עצירה יציב יותר, משום שההחלטה לא התקבלה על סמך frame יחיד אלא על סמך מגמה בזמן.
- השימוש ב-GroupKFold לפי הקלטות אפשר להעריך את המודל בצורה אמינה יותר, מכיוון שכל ההקלטה נשמרה או בקבוצת האימון או בקבוצת הבדיקה, וכך נמנעה דליפת מידע בין train ל-test.
- לסיכום, תוצאות הפרויקט מראות שניתן לבנות מערכת למידת מכונה שמזהה מצב של כוס כמעט מלאה באמצעות ניתוח שמע בלבד. עם זאת, קיימות מגבלות שעדיין דורשות שיפור, כמו תלות בסביבת הקלטה שקטה יחסית, השפעת סוג הכוס על הצליל, וההנחה שקצב המזיגה קבוע בקירוב.
- בעבודת המשך ניתן לשפר את המערכת על ידי מימוש בזמן אמת, הוספת הקלטות עם רעשי רקע, איסוף נתונים מכוסות נוספות, ושימוש בשיטות התאמה מהירה לכוסות חדשות שלא הופיעו באימון.